

Universidad Peruana de Ciencias Aplicadas



INFORME DEL TRABAJO FINAL

CURSO PROCESAMIENTO DE IMÁGENES

Carrera de

CIENCIAS DE LA COMPUTACIÓN

Sección:

SC61

Alumnos:	
Código	Nombres y apellidos
U202210161	Diego Antonio Salinas Casaico
U202216148	Salvador Diaz Aguirre
U202215375	Ricardo Rafael Rivas Carrillo

2024

Índice

Índice.....	1
1. Descripción del caso de uso.....	2
2. Descripción del conjunto de datos (dataset).....	4
3. Propuesta de Modelización.....	5
7. Referencias Bibliográficas.....	12
8. Anexos.....	13

1. Descripción del caso de uso

En los últimos años, el Perú ha experimentado un preocupante crecimiento en los índices de inseguridad ciudadana. La expansión de la delincuencia y el crecimiento de redes criminales afectan en la actualidad a los ciudadanos que desconfían del sistema policial y judicial del país. Los delitos violentos, como robos y homicidios, se han convertido en problemas cotidianos que desafían la capacidad de respuesta de las autoridades. Este escenario ha causado una mayor demanda por parte de la población en medidas de seguridad y prevención de delitos para, de algún modo, disminuir el total de crímenes perpetrados.

La inseguridad en el Perú es un problema grave que afecta a todos los ciudadanos en diferentes niveles. Según el Instituto Nacional de Estadística e Informática (2024) en su informe sobre seguridad ciudadana, entre enero y junio del 2024, el 91% de limeños presentaba la sensación de ser víctima de algún hecho delictivo en los próximos doce meses. Entre los delitos que conforman la inseguridad ciudadana, se encuentra el robo de dinero, cartera o celular en primer lugar, seguido por el robo a la vivienda y la estafa. Estos números comprenden un crecimiento significativo respecto al anterior año en la misma fecha.

Sin embargo, el sentimiento de inseguridad está respaldado por datos del Sistema de Denuncias Policiales (SIDPOL), donde se ha registrado un crecimiento de 13,6% denuncias por comisión de delitos comparado al trimestre enero-marzo del 2022. (INEI, 2024)

¿Cómo comprobamos esta relación? Para la relación entre las bandas y los tatuajes, Pérez (2022) concluyó, que son usados por las pandillas como táctica de intimidación hacia otras, como rituales de iniciación, expresión del tipo de crímenes y la identificación de jerarquía dentro de las bandas.

Para mantener una muestra del tipo de pandillas en las que nos vamos a concentrar, tenemos que especificar muy bien para evitar problemas éticos, gracias a (Pozo 2023), en su tesis habla de los tipos de pandillas, en las que haremos énfasis es en las “infractoras” las cuales adoptan comportamientos violentos, manifestando esta conducta a

través de robos, asaltos y alteración del orden público, y se distinguen por generar inquietud en las calles.

La identificación de estos tatuajes es clave para poder identificar a los miembros de pandillas y desarticular sus redes criminales. Sin embargo, el proceso de identificación manual de tatuajes es lento y costoso. Además, es difícil encontrar expertos en tatuajes que puedan identificar con precisión los símbolos y patrones característicos de cada pandilla.

Por ello, se propone el desarrollo de un sistema automatizado para el reconocimiento de tatuajes de pandillas. Este sistema utilizaría técnicas de procesamiento de imágenes y aprendizaje automático para analizar y clasificar los tatuajes, facilitando la identificación de los miembros de pandillas y apoyando a las autoridades en su pronta captura.

Sin embargo, es necesario tener en cuenta las complicaciones éticas que un proyecto de esta forma supone. Para llevar a cabo esta solución en un contexto real, se necesita el consentimiento de los sujetos a los que se les harán las pruebas, informándoles cómo y para qué se utilizará su imagen. Tratar directamente con los datos de una persona interfiere directamente con su derecho a la protección de su privacidad, por lo que para que se tenga control del uso de información personal, se podría implementar un acuerdo legal de consentimiento. Además, es importante definir nuestros caso de uso y políticas para la aplicación, de manera que podamos minimizar su utilización de manera inapropiada, ya sea para vigilancia masiva o discriminación.

Este sistema será capaz de procesar imágenes y extraer características distintivas de los tatuajes, como formas, patrones y colores, para comparar y encontrar coincidencias con tatuajes previamente registrados en bases de datos policiales. El objetivo es mejorar la eficiencia en la identificación de sospechosos vinculados a pandillas, contribuir a la reducción de la delincuencia organizada en Lima y aumentar la seguridad ciudadana en la capital peruana.

2. Descripción del conjunto de datos (dataset)

El conjunto de datos se titula “tattoo_v0” y proviene del usuario “Drozdik” de la plataforma Hugging Face. Contiene 4370 observaciones, que conforman las variables “image” y “text”. Hemos elegido este conjunto de datos debido a la gran variedad de imágenes que contiene y que podemos procesar automáticamente. Además, al contar con la descripción de cada imagen, nos facilita identificar patrones y realizar filtros, agrupar por características y crear nuevas variables.

Variable	Descripción
image	imagen de tatuajes creados en computadora en un fondo blanco
text	descripción corta de los tatuajes

Para una mejor visualización de los datos, hemos creado nuevas variables:

Variable	Descripción
skull	1 si la imagen contiene una calavera, 0 si no
dragon	1 si la imagen contiene un dragón, 0 si no
knife	1 si la imagen contiene un cuchillo, 0 si no
star	1 si la imagen contiene una estrella, 0 si no
demon	1 si la imagen contiene un demonio, 0 si no
eye	1 si la imagen contiene un ojo, 0 si no

3. Propuesta de Modelización.


Edge Detection: Es una técnica la cual identifica los objetos gracias a la detección de sus contornos en los cambios bruscos de los píxeles de una imagen. Se escogió esta técnica aprendida en clase gracias a que estos bordes ayudan a simplificar una imagen y facilita la identificación de las formas y características clave en una imagen. Además, de que no pierden su forma completa al pasarle otros filtros.

Mask_RCNN: Mask_RCNN usa una técnica de Template Matching, la cual identifica partes de una imagen e intenta buscar la similitud en otra, gracias al template previamente establecido. Este template lo consideramos como el modelo a usar, ya que cumple con las necesidades del proyecto utilizando las imágenes de los tatuajes en su modelo de entrenamiento. Además, se puede adaptar a múltiples dificultades, como el ruido en la imagen o la baja resolución, debido a que este modelo acepta filtros de convolución, los cuales son útiles para mejorar el rendimiento.

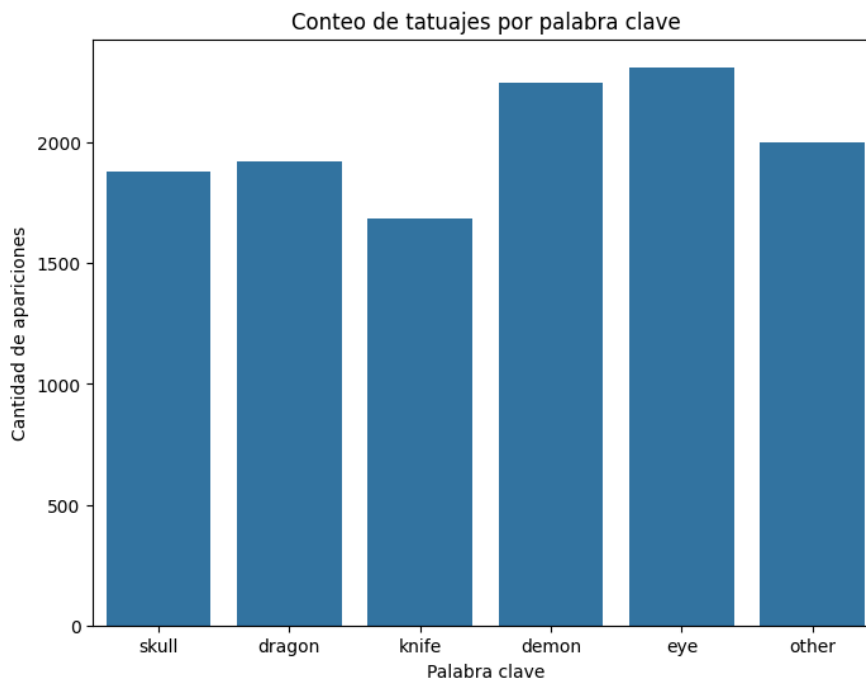
4. Modelización:

Para el uso del modelo, primero se realizó un aumento de datos en el dataframe existente. De esta manera, además de aumentar la cantidad de imágenes totales para entrenar el modelo de forma más precisa, balanceamos muchas de las etiquetas que de otra manera estaban muy asimétricas.

Inicialmente:



Luego del pre-procesamiento:



El uso del dataset de COCO (Common Objects in Context). Es un modelo pre-entrenado crucial para la detección de objetos, segmentación y captioning dataset. Teniendo clases pre establecidas como cabezas y algunos dibujos que son cruciales para el uso correcto del modelo Mask R-CNN

```
# Descarga los pesos preentrenados en el conjunto de datos COCO
!wget https://github.com/matterport/Mask_RCNN/releases/download/v2.0/mask_rcnn_coco.h5
```

Para el modelo tradicional hemos escogido edge-detection, el cual nos creó máscaras a partir de nuestro dataset balanceado y aumentado. Estas al ser generadas fueron etiquetadas en las carpetas, para luego ser usadas en una función que el porcentaje de sus similitudes



```
# Comparar una imagen con las máscaras organizadas
image_path = "/content/test_image.jfif"
best_class, similarity = compare_with_labels(image_path, "organized_masks")

print(f"La imagen coincide mejor con la clase: {best_class} (Similitud: {similarity:.2f})")

La imagen coincide mejor con la clase: dragon (Similitud: 0.06)
```


Para el entrenamiento del modelo de Mask R-CNN, se creó una clase Tatuajes que formaliza y etiqueta las imágenes del dataset, lo que permite al modelo identificar patrones en los tatuajes y clasificarlos según las palabras clave consideradas peligrosas, así como en un grupo adicional de tatuajes no peligrosos. Gracias a que el modelo se basa en ResNet-50, se aprovecha su capacidad para aprender de imágenes complejas, como las de nuestro caso. Además, se agregaron capas de Dropout para evitar el overfitting, se utilizaron dos capas densas, con una capa intermedia que consideramos suficiente debido al uso de ResNet y se utilizó la función de activación Relu, crucial en modelos de visión computacional para clasificar imágenes, porque permite que el modelo aprenda representaciones complejas y no lineales de los datos visuales.

```
import torch.nn as nn
import torchvision.models as models

# Configurar el dispositivo (GPU si está disponible, sino CPU)
device = torch.device('cuda' if torch.cuda.is_available() else 'cpu')

# Definir el modelo de ResNet preentrenado
class TattooModel(nn.Module):
    def __init__(self, num_classes=6):
        super(TattooModel, self).__init__()
        self.model = models.resnet50(pretrained=True)

        # Agregar dropout y una capa adicional
        num_features = self.model.fc.in_features
        self.model.fc = nn.Sequential([
            nn.Dropout(0.5),
            nn.Linear(num_features, 512),
            nn.ReLU(),
            nn.Dropout(0.3),
            nn.Linear(512, num_classes)
        ])

    def forward(self, x):
        return self.model(x)
```

Dentro del entrenamiento, fue iniciado en 10 épocas para evitar errores de segmentación y sobre-entrenamientos. Dándonos como resultado un modelo mucho más robusto:

```
Epoch 9/10 - Batch 0/262 - Loss: 0.2308
Epoch 9/10 - Batch 50/262 - Loss: 0.2128
Epoch 9/10 - Batch 100/262 - Loss: 0.2796
Epoch 9/10 - Batch 150/262 - Loss: 0.2922
Epoch 9/10 - Batch 200/262 - Loss: 0.2549
Epoch 9/10 - Batch 250/262 - Loss: 0.2037
Epoch 9/10:
Average Training Loss: 0.3372
Average Validation Loss: 0.3423
Epoch 10/10 - Batch 0/262 - Loss: 0.4884
Epoch 10/10 - Batch 50/262 - Loss: 0.1901
Epoch 10/10 - Batch 100/262 - Loss: 0.4768
Epoch 10/10 - Batch 150/262 - Loss: 0.2906
Epoch 10/10 - Batch 200/262 - Loss: 0.2449
Epoch 10/10 - Batch 250/262 - Loss: 0.3039
Epoch 10/10:
Average Training Loss: 0.3204
Average Validation Loss: 0.3573
```

Dentro de la función de predicción, tiene en cuenta las etiquetas del modelo y evalúa la imagen con los patrones que obtuvo de las imágenes etiquetadas para luego mostrarnos el porcentaje de similitudes

Imagen Original



Probabilidades por Categoría



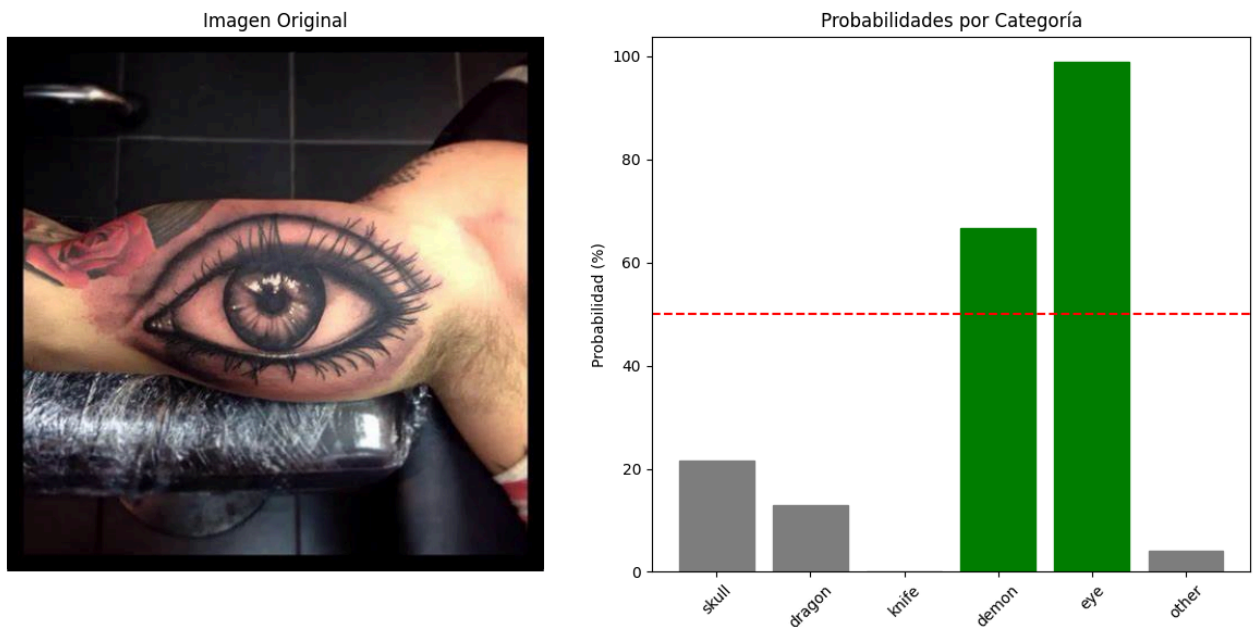


Imagen Original



Probabilidades por Categoría





5. Publicación de los resultados.

Los resultados obtenidos se analizaron mediante métricas clave como precisión, recall, y

F1-Score para cada categoría. La siguiente tabla resume el desempeño por clase:


	precision	recall	f1-score	support
skull	0.96	0.59	0.73	363
dragon	0.89	0.92	0.90	373
knife	0.72	0.99	0.83	236
demon	0.90	0.84	0.87	470
eye	0.67	0.88	0.76	236
other	0.95	0.94	0.95	414
accuracy			0.85	2092
macro avg	0.85	0.86	0.84	2092
weighted avg	0.87	0.85	0.85	2092

El modelo final alcanzó su desempeño máximo con las siguientes métricas.

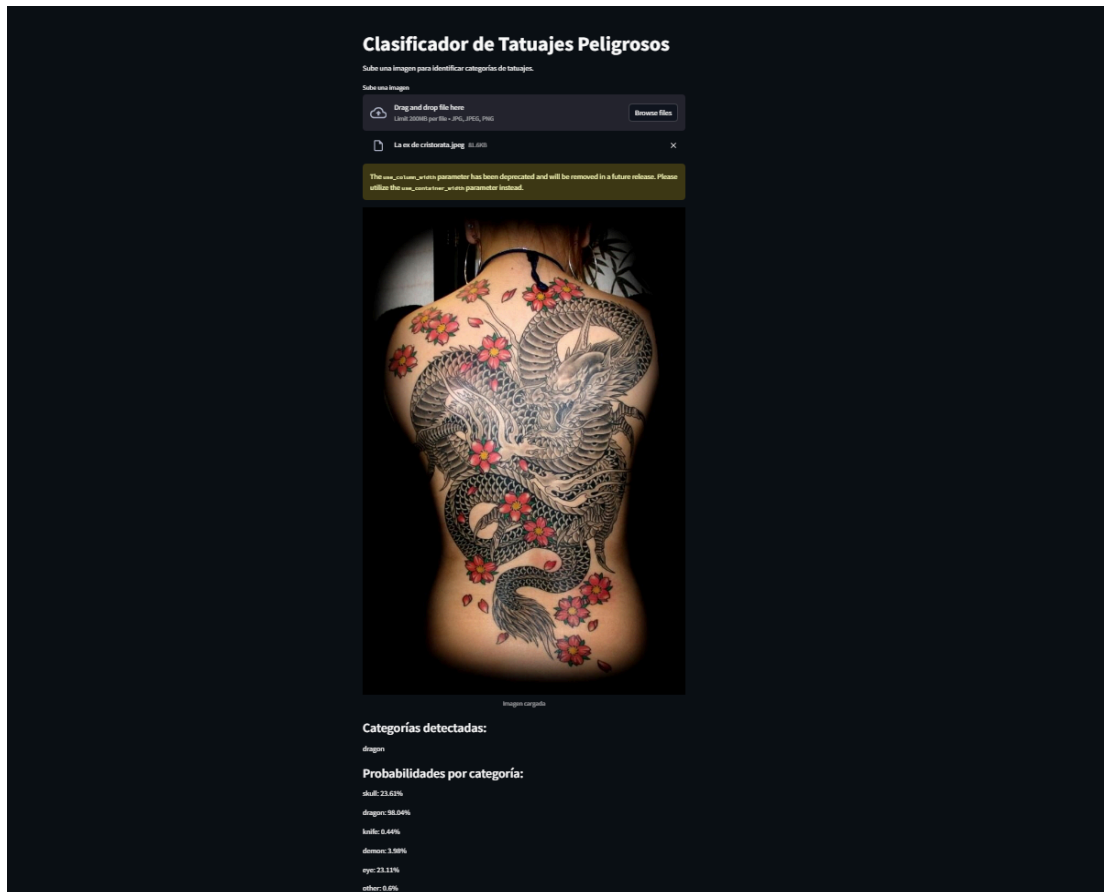
- Precisión: El modelo en general alcanzó un desempeño del 85%, suficiente para que el modelo funcione de forma correcta.

- Recall: El modelo alcanza un 86% en la métrica del recall, la cual indica que si la categoría es positiva, el modelo detecta correctamente el positivo.
- F1-Score: El modelo alcanza un 84% en el F1-Score, la cual es como una combinación entre la precisión y el recall.

Hemos obtenido también una matriz de confusión, la cual nos indica las validaciones que realizó el modelo y en que se equivocó.



El modelo además ha sido implementado junto a una interfaz gráfica usando la herramienta de streamlit, la cual permite al usuario cargar una imagen y analizarla a tiempo real.



6. Conclusiones

- La implementación de clases, el aumento de capas y el data augmentation para el entrenamiento fueron técnicas fundamentales para la creación de este proyecto, ya que mejoraron la diversidad de los datos y la adaptación del modelo a ellos, lo que a su vez optimizó su capacidad para clasificar y segmentar tatuajes.
- En el caso de tatuajes similares, como algunos casos de demonios y dragones, el modelo suele confundirse. Para esto, se podrían agregar más variedad de cada una de las categorías para que aprenda la diferencia con mayor exactitud.
- Los resultados obtenidos, en su mayoría, son satisfactorios. Sin embargo, el modelo a veces flaquea en cuanto a la detección de tatuajes más abstractos o con alteraciones muy distintivas de sus patrones. Lo que genera resultados inesperados.

- Se contempla a futuro el uso de múltiples modelos para la clasificación de personas tatuadas y no tatuadas, con el fin de mejorar la precisión del programa. De esta manera, la predicción no dependerá solo de buscar formas parecidas a los tatuajes proporcionados, sino que primero identificará los cuerpos de las personas y luego detectará el tatuaje.

7. Referencias Bibliográficas

Instituto Nacional de Estadística e Informática (INEI). (2024). Boletín de seguridad ciudadana: Enero-marzo 2024. INEI.

https://www.inei.gob.pe/media/MenuRecursivo/boletines/boletin_seguridad_ene_mar24.pdf

Instituto Nacional de Estadística e Informática (INEI). (2024). *Estadísticas de seguridad ciudadana: Enero-junio 2024*. INEI.

<https://www.inei.gob.pe/media/MenuRecursivo/boletines/estadisticas-de-seguridad-ciudadana-enero-junio-2024.pdf>

División de Estadística de la Policía Peruana, Dirección D E Tecnología. (2023). BOLETÍN ESTADÍSTICO POLICIAL I TRIMESTRE 2023.

<https://www.policia.gob.pe/estadisticopnp/documentos/boletin-2023/Boletin%20I%20Trimestre%202023.pdf>

Pozo, H. F. (2023). SOCIALIZACIÓN DE LOS JÓVENES PARA CONTROLAR LA VIOLENCIA EN LAS CALLES DE LA CIUDAD DE LIMA, AÑO 2022. UNIVERSIDAD JOSÉ CARLOS MARIÁTEGUI.

<https://hdl.handle.net/20.500.12819/2182>

Pérez, E. S. Casado M. (2022). *El uso del tatuaje en bandas criminales*. Universidad Autónoma de Barcelona.

<https://ddd.uab.cat/record/264882>

8. Anexos

[Imagenes.ipynb - Colab \(google.com\)](#)

<https://github.com/20Ricky2010/ProcesamientoImagenes-TF>

[Drozdik/tattoo_v0 · Datasets at Hugging Face](#)

<https://www.clinicachavarri.com/los-tatuajes-y-el-ingreso-a-la-policia-nacional-del-peru/>

https://docs.adaptive-vision.com/Trunk/studio/machine_vision_guide/TemplateMatching.html